

UNIVERSIDADE FEDERAL DE VIÇOSA
CAMPUS DE RIO PARANAÍBA
SISTEMAS DE INFORMAÇÃO

MATHEUS VIEIRA DA SILVA

**OTIMIZAÇÃO DOS PARÂMETROS DE REDES NEURAI
CONVOLUCIONAIS PARA O DIAGNÓSTICO DE
CARDIOMIOPATIA ISQUÊMICA**

RIO PARANAÍBA

2018

MATHEUS VIEIRA DA SILVA

OTIMIZAÇÃO DOS PARÂMETROS DE REDES NEURAIS
CONVOLUCIONAIS PARA O DIAGNÓSTICO DE
CARDIOMIOPATIA ISQUÊMICA

Projeto de Pesquisa apresentado à disciplina
SIN 100 (Tratamento e Análise de dados)
como parte das exigências para a aprovação.
Orientador: Prof. Larissa Ferreira Rodrigues

RIO PARANAÍBA

2018

Resumo

A análise de imagens médicas vem sendo automatizadas com o uso do aprendizado de máquina, que vai desde classificadores estatísticos utilizando engenharia de características extraídas manualmente, a redes neurais modernas fazendo uso do grande volume de dados disponível. Consequentemente, pode ser aplicado aprendizado de máquina para diagnóstico de cardiomiopatia isquêmica, uma doença cardiovascular que leva a insuficiência cardíaca. As Redes Neurais Convolucionais (*Convolution Neural Networks*) tem sido o método de escolha por serem o estado-da-arte no campo, Porém elas falham quando o volume de dados não é suficiente para treina-las, além de terem fraca capacidade de generalização, pois quando ocorrem casos fora do escopo de seu treinamento, precisam ser treinadas novamente o que torna um processo muito custoso computacionalmente. O objetivo deste trabalho é aplicar técnicas de meta-aprendizado para otimizar os parâmetros de uma Rede Neural Convolucional(*CNN*) para que possa ser treinada com uma quantidade baixa de imagens e seja capaz de generalizar para novas situações, com intuito de verificar casos de isquemia cardíaca em pacientes. Propõem-se um método de meta-aprendizado *Model Agnostic Machine Learning*(*MAML*) com algumas modificações extraídas do (*Reptile*) e acrescentando (*curriculum learning*) para a seleção de tarefas. Por fim, avaliar a eficiência da classificação.

Palavras-chaves: meta-aprendizado, análise de imagens médicas, *CNN*, cardiomiopatia isquêmica.

Abstract

Medical image analysis has been automated with the use of machine learning, ranging from statistical classifiers using handcrafted feature engineering, to modern neural networks making use of the big data available. Thus, machine learning can be applied to diagnose ischemic cardiomyopathy, a cardiovascular disease that leads heart failure. Convolutional Neural Networks have been the method of choice because they are state-of-the-art in the field, but they fail when data is insufficient to train it, Besides having low capacity of generalization, because when occur cases out of the scope of their training, it needs to be trained again which makes a process very costly computationally. The objective of this work is to apply meta-learning techniques to optimize the parameters of a Convolutional Neural Network (CNN) so that it can be trained with a small number of images and be able to generalize to new situations, in order to verify cases of cardiac ischemia in patients. A meta-learning method is proposed Model Agnostic Machine Learning (MAML) with some modifications extracted from the (Reptile) and adding (curriculum learning) to the selection of tasks. Finally, evaluate the efficiency of the classification.

Key-words: meta-learning, medical image analysis, CNN, ischemic cardiomyopathy.

Lista de ilustrações

Figura 1 – função de activação <i>ReLU</i> . Medium	10
Figura 2 – Intuição por trás do algoritmo de meta-aprendizado. A cada interação a fase de meta-treinamento inicia os parâmetros de tal forma, que maximiza a adaptação da rede neural em novas tarefas. UC Berkeley . .	12
Figura 3 – A imagem mostra o pseudocódigo do algoritmo de meta-aprendizado em sua forma mais geral. Os parâmetros α e β podem ser ajustados manualmente ou aprendidos pelo <i>backpropagation</i> . UC Berkeley	12

Lista de tabelas

Tabela 1 – Cronograma Normal	16
--	----

Sumário

1	Introdução	7
1.1	Objetivo Geral	8
1.2	Objetivos Específicos	8
2	Referencial Teórico	9
2.1	Isquemia Cardíaca	9
2.1.1	Fisiopatologia	9
2.2	Redes Neurais Convolucionais <i>CNNs</i>	10
2.3	Meta-Aprendizado	11
2.3.1	<i>Reptile (Open AI)</i>	13
3	Trabalhos Relacionados	14
4	Metodologia e Cronograma	15
4.1	Ferramentas Computacionais	15
4.2	Aquisição do <i>Dataset</i>	15
4.3	Pré-processamento	15
4.4	Classificação	16
4.4.1	Modelo	16
4.5	Cronograma	16
5	Resultados Esperados	17
	Referências	18

1 Introdução

A cardiomiopatia isquêmica é um dos principais problemas de saúde no mundo, representando significativa parcela da mortalidade nos dias atuais. É uma doença na qual se caracteriza a presença de isquemia do miocárdio associada ou não a fibrose causada pelo infarto miocárdico. A isquemia miocárdica só ocorre quando há desequilíbrio na oferta ou demanda de oxigênio e a diminuição do fluxo sanguíneo é considerada a fisiopatologia da maioria dos casos de infarto (PESTANA, 2017).

O diagnóstico baseia-se na história clínica e na presença de fatores de risco. O eletrocardiograma e radiografia de tórax também podem ser métodos esclarecedores em pacientes com dor torácica. A cineangiocoronariografia é, entretanto, o exame padrão ouro para o diagnóstico de Doença Arterial Coronariana (DAC), sendo, no entanto, um exame invasivo e dispendioso. Atualmente, a imagem cardíaca não invasiva tem sido fundamental para o diagnóstico e manejo de pacientes com diagnóstico ou com suspeita de doença coronariana crônica. Os exames não invasivos mais frequentemente utilizados no diagnóstico da cardiomiopatia isquêmica são o teste ergométrico, o ecocardiograma sob estresse farmacológico ou com exercício, a cintilografia miocárdica de perfusão, a ressonância magnética cardíaca (RMC) e a tomografia computadorizada cardíaca (TCC)(ASSUNÇÃO et al., 2016). Os dois últimos são úteis para o diagnóstico automático utilizando aprendizado profundo.

Aprendizado profundo é uma técnica que permite modelos computacionais compostos por várias camadas de processamento, a aprenderem representações nos dados com múltiplos níveis de abstração. Os modelos aprendem uma complexa estrutura em grandes *datasets* utilizando o algoritmo *backpropagation* para indicar como a máquina deve ajustar seus parâmetros internos, que são usados para calcular as representações de cada camada (LECUN; BENGIO; HINTON, 2015).

As Redes Neurais Convolucionais (do inglês *Convolutional Neural Networks - CNN*) têm se mostrado muito eficazes na classificação de imagens, utilizando uma grande quantidade de dados e poder de processamento paralelo disponível por meio de GPUs, elas são capazes de classificar as imagens corretamente com uma taxa de erros relativamente baixa (KRIZHEVSKY; SUTSKEVER; HINTON, 2012). As *CNNs* têm sido utilizadas também no diagnóstico médico auxiliado por computador, com destaque para classificação de imagens cardiovasculares (LITJENS et al., 2017).

As imagens 3D de alta resolução geradas pela tomografia computadorizada cardíaca são pré-processadas e inseridas nas camadas de entrada das redes neurais convolucionais (LIDAYOVÁ et al., 2017). Porém as *CNNs* necessitam de muitos dados para o seu

treinamento, e elas não conseguem bons resultados em *datasets* pequenos, pois pode gerar *overfitting*. Para resolver esse problema, tem se desenvolvido técnicas de aprendizado que requerem uma pequena quantidade de dados na fase de treinamento (SANTORO et al., 2016; FINN; ABBEEL; LEVINE, 2017). A principal ideia dessa nova área, então chamada de meta-aprendizado, é otimizar o processo de aprendizado das redes neurais, com isso é possível treinar um modelo em uma vasta gama de tarefas de aprendizado de tal maneira que possa resolver novas tarefas utilizando apenas uma pequena quantidade de amostra de treinamento.

1.1 Objetivo Geral

Obter um nível de acurácia relativamente alto na classificação de imagens cardiovasculares obtidas por meio de tomografia computadorizada disponíveis em um *dataset*, utilizando o mínimo de dados possível para treinar uma rede neural convolucional aplicando meta-aprendizado para resolver efetivamente problemas de *overfitting* e generalização para novas tarefas.

1.2 Objetivos Específicos

- Avaliar diferentes técnicas de classificação de imagens que estão sendo utilizadas.
- Comparar essas diferentes técnicas
- Propor uma solução que resolva os problemas apresentados
- Avaliar as diferentes variações da solução proposta

2 Referencial Teórico

Neste capítulo são abordados conceitos que embasam o desenvolvimento deste trabalho. Onde serão apresentados conceitos de isquemia cardíaca, como ela se desenvolve quais são as principais complicações da doença, diagnóstico e tratamento. Posteriormente serão apresentados os problemas no diagnóstico automático da doença por meio do aprendizado profundo, e apresenta-se os conceitos a serem usados na solução proposta no trabalho.

2.1 Isquemia Cardíaca

A cardiopatia isquêmica designa um grupo de síndromes fisiologicamente relacionados associados a isquemia do miocárdio. É a principal causa de morte e morbidade em ambos os sexos nos países ocidentais. Além dos fatores de risco tradicionais, outros têm sido estudados e sugeridos. A dor pré-cordial é o sintoma mais característico, tendo diferentes características conforme se trate de angina estável, instável ou enfarte agudo do miocárdio. O diagnóstico baseia-se na história clínica, no exame objectivo e em exames complementares de diagnóstico, que podem incluir exames funcionais, exames anatômicos e, em casos específicos, a coronariografia. O tratamento inclui alterações no estilo de vida e fármacos para redução de sintomas anginosos e de eventos adversos. A revascularização pode ser percutânea por angioplastia ou cirúrgica através de *bypass* coronário, sendo aplicada apenas em casos específicos (CARVALHO; SOUSA, 2001).

2.1.1 Fisiopatologia

Na fisiopatologia da cardiopatia isquêmica dois processos estão implicados: a oferta e a demanda de oxigênio pelo miocárdio. A isquemia miocárdica ocorre quando há desequilíbrio na oferta e na demanda de oxigênio. Por outro lado, duas situações alteram a oferta de oxigênio para o miocárdio: a isquemia e a hipoxemia. Em algumas condições, o comprometimento da oferta de oxigênio é secundário à diminuição do fluxo sanguíneo, sendo essa a fisiopatologia da maioria dos casos de infarto agudo do miocárdio (IAM) e dos episódios de angina instável. Em outras situações, como a hipertrofia ventricular, o aumento na demanda de oxigênio é o principal responsável pela isquemia miocárdica (PINHEIRO et al., 2017).

2.2 Redes Neurais Convolucionais *CNNs*

As *CNNs* fazem uso dos filtros para detectar características em uma imagem, esses filtros são treinados para detectar características específicas, como bordas por exemplo (essa operação é denominada de convolução). a saída de cada camada de convolução então é passada por uma função de ativação não linear, Geralmente a função escolhida é a *Rectified Linear Unit ReLU* (figura 1). Posteriormente as características extraídas na




Figura 1 –

ReLU produz zero em metade do seu domínio. Como consequência, as derivadas se mantêm grandes enquanto a unidade estiver ativa Medium

convolução, são organizadas em um vetor de características, esse vetor é totalmente conectado com várias camadas de neurônios, a estrutura de cada camada pode ser representada pela fórmula :

$$\sum_{i=1}^n (W_i X_i + b)$$

onde W_i , X_i e b são os pesos, dados de entrada e *biases*, respectivamente. Cada camada de neurônios também passa por uma função de ativação, *ReLU* é mais uma vez utilizado exceto na última camada que a função *softmax* é empregada, onde X_j são os neurônios da camada.

$$\sigma(X_j) = \frac{e^{x_j}}{\sum_i e^{x_i}}$$

Por último os parâmetros do modelo W e b são atualizados considerando o erro gerado na camada de saída, o algoritmo utilizado é o *backpropagation*, sua função é computar as derivadas parciais do parâmetros da função e atualizar os pesos e *biases* com o objetivo de minimizar uma função de custo. Quando essa função de custo for 0 significa

que o modelo convergiu e todos os parâmetros estão otimizados para reconhecer o padrão apresentado na fase de treinamento.

Uma das principais limitações das redes neurais modernas, é sua ineficiência no aprendizado, para reconhecer um simples dígito é necessário milhares de exemplos na fase de treinamento. Mesmo diferentes *CNNs* conseguindo atingir taxas de erro menores do que humanos na classificação de imagens (HE et al., 2016), para esse feito, são necessárias milhões de imagens rotuladas, e um custo computacional muito alto. Os seres humanos por outro lado, tem uma característica vantajosa nesse sentido, eles conseguem aprender rapidamente com poucos exemplos e generalizar para outras tarefas. Inspirados por essas características, pesquisadores tem tentado desenvolver algoritmos mais robustos que imitam o processo de aprendizado humano, em uma área denominada meta-aprendizado.

2.3 Meta-Aprendizado

A ideia central do meta-aprendizado pode ser definida como um processo de otimização de alto nível que otimiza um processo de baixo nível, utilizando essas ideias, pode-se gerar modelos mais rápidos e capazes de generalizar para mais tarefas (ANDRYCHOWICZ et al., 2016). Podem ser aplicados para diversos tipos de redes neurais em aprendizado supervisionado e não supervisionado, e também aprendizado por reforço,

Model Agnostic Meta-Learning (*MAML*) tem se mostrado muito eficaz na resolução de problemas de classificação, regressão e aprendizado por reforço, suas principais vantagens são a compatibilidade com qualquer modelo treinado com *backpropagation* e não inclui nenhum parâmetro adicional. A intuição por trás do algoritmo está representada na Figura 2.

Formalmente de maneira mais geral o algoritmo na fase de meta-treinamento pode ser descrito na figura 2. Onde $T = [L(x_1, a_1, \dots, x_H, a_H), q(x_1), q(x_t + 1|x_t, a_t), H]$, a função de custo é definida por L , $q(x_1)$ é a distribuição inicial sobre as observações, a função de transição $q(x_t + 1|x_t, a_t)$ e por último, um episódio de comprimento, que neste caso $H = 1$ quando se tratar de aprendizado supervisionado. O modelo vai gerar amostras de comprimento H escolhendo cada saída a_t a cada tempo t .

No cenário de meta-aprendizado é considerado a distribuição sobre as tarefas $p(T)$, para que o modelo seja capaz de adapta-lo, o modelo é treinado a aprender uma nova tarefa T_i representada por $p(T)$ de apenas K amostras representas por q_i e *feedback* L_t gerado por T_i . Durante o treinamento a tarefa T_i é amostrada de $p(T)$, então modelo é treinado com K exemplos e *feedback* dos correspondentes custos L_t de T_i , e depois são testadas em novas amostras de T_i . O modelo f é então otimizado considerando como os erros de teste nos novos dados de q_i mudam em relação a seus parâmetros. No final do meta-treinamento novas tarefas são amostradas de $p(T)$ e a meta-performance é medida,

geralmente tarefas meta-teste usadas em meta-treinamento.

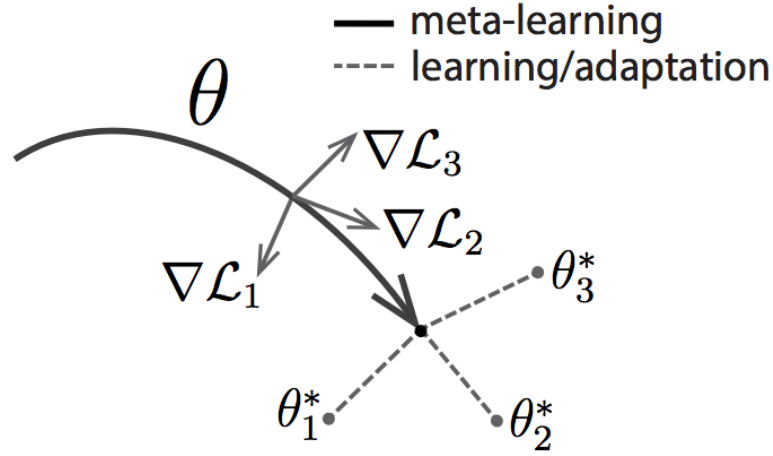


Figura 2 – Intuição por trás do algoritmo de meta-aprendizado. A cada interação a fase de meta-treinamento inicia os parâmetros de tal forma, que maximiza a adaptação da rede neural em novas tarefas. UC Berkeley

Algorithm 1 Model-Agnostic Meta-Learning

Require: $p(\mathcal{T})$: distribution over tasks

Require: α, β : step size hyperparameters

```

1: randomly initialize  $\theta$ 
2: while not done do
3:   Sample batch of tasks  $\mathcal{T}_i \sim p(\mathcal{T})$ 
4:   for all  $\mathcal{T}_i$  do
5:     Evaluate  $\nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$  with respect to  $K$  examples
6:     Compute adapted parameters with gradient descent:  $\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$ 
7:   end for
8:   Update  $\theta \leftarrow \theta - \beta \nabla_{\theta} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta'_i})$ 
9: end while
```

Figura 3 – A imagem acima mostra o pseudocódigo do algoritmo de meta-aprendizado em sua forma mais geral. Os parâmetros α e β podem ser ajustados manualmente ou aprendidos pelo *backpropagation*. UC Berkeley

Na Figura 3, f_{θ} é o modelo definido como uma função parametrizada onde seus parâmetros são θ . Quando adaptando para novas tarefas \mathcal{T}_i os parâmetros do modelo θ se tornam θ' , a atualização do parâmetro θ_i é computada usando atualização de descida de gradiente (meta-otimização) na tarefa \mathcal{T}_i . Os parâmetros do modelo são treinados otimizando a performance de f_{θ} levando em conta θ em todas as tarefas amostrais de

$p(T)$. A meta-otimização é realizada via descida de gradiente estocástico, de tal forma que os parâmetros são atualizados de acordo com a seguinte equação:

$$\theta \leftarrow \theta - \beta \nabla_{\theta} \sum_{T_i \sim p(T)} L_{T_i}(f_{\theta_i})$$

Em MAML a atualização dos meta-gradientes é realizada por gradiente através de gradientes, computacionalmente é necessário calcular o produto de vetores hessianos.

2.3.1 *Reptile (Open AI)*

Recentemente pesquisadores da *OpenAI* (Uma empresa sem fins lucrativos para pesquisa de inteligência artificial) publicaram um artigo, (NICHOL; ACHIAM; SCHULMAN, 2018) onde eles desenvolveram um algoritmo de meta-aprendizado chamado *Reptile*, que funciona repetidamente amostrando uma tarefa utilizando *Stochastic Gradient Descent* (SGD) e atualizando os parâmetros iniciais em direção aos parâmetros finais aprendidos na tarefa.

Assim com *MAML*, *Reptile* procura por uma inicialização nos parâmetros de uma rede neural, de tal maneira que a rede pode ser tunada usando uma pequena quantidade de dados de uma nova tarefa. Mas enquanto *MAML* computa derivadas de segunda ordem em grafos computacionais através da decida de gradiente, *Reptile* realiza decida de gradiente estocástica (*SGD*) em cada tarefa. Isso torna *Reptile* computacionalmente mais eficiente, e utiliza menos memória no processo de meta-treinamento.

3 Trabalhos Relacionados

Utilizar meta-aprendizado em algumas situações na análise de imagens médicas pode ser uma solução viável, pelo fato de que, nem sempre o montante de dados necessário esta disponível, ou o custo computacional pode ser muito elevado para atingir o nível de acurácia humana, e nem sempre os modelos tradicionais são eficientes em generalizar como médicos. Para resolver esse problema Maicas et al. (2018) utilizam técnicas meta-aprendizado em imagens de Raio-x fracamente-rotuladas(que apresentam rótulos com aspectos globais), também introduz um novo método de seleção de tarefas que não seja aleatório, baseado em *Teacher-Student Curriculum Learning* (MATIISEN et al., 2017). Sua metodologia consiste em três estágios, primeiro o modelo passa por uma fase de meta-treinamento usando diferentes tarefas(cada contendo uma pequena quantidade de amostra de treinamento), quando for encontrada uma boa inicialização, No segundo estágio o modelo será treinado com base nos parâmetros iniciais que foram computados na fase de meta-treinamento, e por último ocorre a inferência. Os resultados mostram uma acurácia de 0.9 que atualmente é o estado-da-arte no campo.

Os algoritmos tradicionalmente empregados em análise de imagens médicas desenvolvidos conseguem uma classificação com níveis de precisão muito altos (LITJENS et al., 2017). Em problemas cardiovasculares Nirschl et al. (2018) emprega várias arquiteturas de redes neurais convolucionais diferentes para detectar pacientes com insuficiência cardíaca, utilizando técnicas como aumento dos dados, validação cruzada (dividir o *dataset* em *k-folds* com o objetivo de evitar *overfitting*) e ajustando os parâmetros do modelo manualmente, como o número de camadas, taxa de aprendizado e tamanho de lotes, é possível o diagnóstico de insuficiência cardíaca em pacientes com sucesso. Porém existem vários problemas abordados, dentre eles o tamanho do *dataset* que leva todas as arquiteturas ao *overfitting*, São realizadas várias técnicas para resolver esse problema, um deles é o métodos de regularização *dropout*(que consiste em remover vários neurônios aleatoriamente da rede), entretanto não resolvem eficientemente os problemas propostos.

4 Metodologia e Cronograma

Neste capítulo são descritos os métodos propostos para o desenvolvimento deste trabalho. Estes quando implementados e testados deverão contribuir para diagnósticos cardiovasculares em geral, utilizando poucos recursos na obtenção de dados para o treino das *CNNs*.

4.1 Ferramentas Computacionais

Para este trabalho será utilizada a linguagem de programação python¹ que é largamente empregada para computação científica, tendo suporte para varias bibliotecas voltadas para inteligência artificial e aprendizado de máquina como *TensorFlow*² e *PyTorch*³, além de outras bibliotecas como *NumPy*⁴ para manipulação de arranjos e matrizes.

4.2 Aquisição do *Dataset*

As imagens foram obtidas na base de dados *In-Vivo Human Heart CT Image Data*⁵ que conta com amostras cardíacas do ventrículo esquerdo obtidas de 11 pacientes utilizando um multi-detector de alta resolução para tomografia computadorizada cardíaca. As imagens estão classificadas em pacientes diagnosticados com isquemia cardíaca e pacientes com diagnóstico negativo.

4.3 Pré-processamento

Nessa etapa serão aplicadas algumas técnicas de pré-processamento de imagens para obter melhores resultados nas métricas escolhidas (PAL; SUDEEP, 2016). O objetivo é melhorar a qualidade das imagens por meio da aplicação de filtros como média e mediana para a redução de ruído. Os dados serão normalizados e dimensões ajustadas para a etapa de classificação.

¹ Disponível em: <http://www.python.org>.

² Disponível em <https://www.tensorflow.org/>

³ Disponível em <https://pytorch.org/>

⁴ Disponível em <http://www.numpy.org/>

⁵ Disponível em <http://cvrgrid.org/data/in-vivoreferenceA>

4.4 Classificação

A arquitetura de escolha para este trabalho foi uma rede neural convolucional padrão *AlexNet*. Pretende-se construir um modelo que será meta-treinado utilizando um número k de imagens para realizar a amostragem de tarefas. O modelo meta-treinado então será usado para inicializar os parâmetros da *CNN* no processo de treinamento comum de aprendizado profundo. Tendo com base o referencial teórico, propõem-se uma combinação do algoritmo (Reptile) e o novo método de seleção de tarefas (*curriculum learning*) proposto pelo Maicas et al. (2018).

4.4.1 Modelo

O modelo vai seguir o seguinte *script*: Definir um vetor para os parâmetros da *CNN*. Considerar uma distribuição de tarefas sob o *dataset*. Atualizar o vetor de parâmetros. As tarefas serão divididas em meta-treinamento e meta-teste, sendo selecionadas por meio do método (*curriculum learning*) ao invés de serem aleatórias, o erro será calculado com gradientes de primeira ordem, como propõe Nichol, Achiam e Schulman (2018) fazendo uso da função de otimização *SGD* (*Stochastic Gradient Descent*), o erro será atualizado em cada tarefa e não por lotes. Serão consideradas as funções de ativação (*ReLU*) e (*softmax*), a função de custo será entropia cruzada binária.

4.5 Cronograma

Tabela 1 – Cronograma do Projeto em Meses

Atividade	1	2	3	4	5	6	7	8	9	10	11	12
Revisão Bibliográfica	•	•										
Métodos			•	•	•	•						
Testes				•	•	•	•					
Resultados							•	•				
Conclusão									•	•		
Banca										•	•	•

5 Resultados Esperados

Com a execução do projeto espera-se encontrar uma inicialização otimizada para os parâmetros da rede neural de tal forma que classifique os casos de isquemia cardíaca corretamente. Avaliar a performance obtida, irá contribuir para pesquisas futuras na área e poderá auxiliar cardiologistas no diagnóstico de doenças cardíacas.

Referências

- ANDRYCHOWICZ, M. et al. Learning to learn by gradient descent by gradient descent. In: LEE, D. D. et al. (Ed.). **Advances in Neural Information Processing Systems 29**. Curran Associates, Inc., 2016. p. 3981–3989. Disponível em: <<http://papers.nips.cc/paper/6461-learning-to-learn-by-gradient-descent-by-gradient-descent.pdf>>.
- ASSUNÇÃO, F. B. et al. Cardiac magnetic resonance imaging and computed tomography in ischemic cardiomyopathy: an update. **Radiologia brasileira**, SciELO Brasil, v. 49, n. 1, p. 26–34, 2016.
- CARVALHO, A. C.; SOUSA, J. M. A. Cardiopatia isquêmica. **Rev Bras Hipertens**, v. 8, n. 3, p. 297–305, 2001.
- FINN, C.; ABBEEL, P.; LEVINE, S. Model-agnostic meta-learning for fast adaptation of deep networks. **arXiv preprint arXiv:1703.03400**, 2017.
- HE, K. et al. Deep residual learning for image recognition. In: **Proceedings of the IEEE conference on computer vision and pattern recognition**. [S.l.: s.n.], 2016. p. 770–778.
- KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. In: PEREIRA, F. et al. (Ed.). **Advances in Neural Information Processing Systems 25**. Curran Associates, Inc., 2012. p. 1097–1105. Disponível em: <<http://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks.pdf>>.
- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **nature**, Nature Publishing Group, v. 521, n. 7553, p. 436, 2015.
- LIDAYOVÁ, K. et al. Classification of cross-sections for vascular skeleton extraction using convolutional neural networks. In: SPRINGER. **Annual Conference on Medical Image Understanding and Analysis**. [S.l.], 2017. p. 182–194.
- LITJENS, G. et al. A survey on deep learning in medical image analysis. **Medical image analysis**, Elsevier, v. 42, p. 60–88, 2017.
- MAICAS, G. et al. Training medical image analysis systems like radiologists. **arXiv preprint arXiv:1805.10884**, 2018.
- MATIISEN, T. et al. Teacher-student curriculum learning. **arXiv preprint arXiv:1707.00183**, 2017.
- NICHOL, A.; ACHIAM, J.; SCHULMAN, J. On first-order meta-learning algorithms. **CoRR**, abs/1803.02999, 2018. Disponível em: <<http://arxiv.org/abs/1803.02999>>.
- NIRSCHL, J. J. et al. A deep-learning classifier identifies patients with clinical heart failure using whole-slide images of h&e tissue. **PloS one**, Public Library of Science, v. 13, n. 4, p. e0192726, 2018.

PAL, K. K.; SUDEEP, K. Preprocessing for image classification by convolutional neural networks. In: IEEE. **Recent Trends in Electronics, Information & Communication Technology (RTEICT), IEEE International Conference on.** [S.l.], 2016. p. 1778–1781.

PESTANA, I. M. L. **Cardiopatía isquêmica e osteoporose**. Tese (Doutorado), 2017.

PINHEIRO, F. K. et al. Análise das inter-relações dos sinais vitais em pacientes portadores e não portadores de cardiopatía isquêmica. Universidade Federal de Santa Maria, 2017.

SANTORO, A. et al. Meta-learning with memory-augmented neural networks. In: **International conference on machine learning**. [S.l.: s.n.], 2016. p. 1842–1850.